


Harness不是目的，知识才是护城河 —— 一个AI工程交付团队的知识沉淀实践

原创 腾讯程序员 腾讯技术工程 2026年5月11日 17:36 广东



作者：stevenpxiao

当 Harness Engineering 成为 2026 年最热门的 AI 工程话题，业界争论焦点集中在“该用多大的模型”还是“该搭多复杂的工作流”时，我们团队在落地实践中发现了一个被低估的事实——**构建 Harness 工作流不是最终目的，私域和团队知识的沉淀才是真正的技术护城河**。本文分享我们在 AI Team 工程交付编排系统中，如何设计知识分层架构、如何让团队知识库共建共享、如何让工作流成为知识沉淀的载体、如何突破人机交互瓶颈实现随时随地的 workflows 流转，以及我们的落地经验和思考。

一、从 Harness Engineering 热潮说起

2025 年末至 2026 年初，AI 工程领域掀起了一场关于 **Harness Engineering** 的热烈讨论。这个术语源自“harness”（马具）的隐喻——就像骑师通过缰绳和马鞍来**引导**马的力量走正确的方向，而非增强马本身的体能，Harness Engineering 强调的是**引导和约束 AI 模型的能力**，而非提升模型本身。

从三大标志性实践来看，不同团队对 Harness Engineering 的侧重各有不同：

实践方	核心关注	关键动作
OpenAI — Codex	人机交互协议	零手写代码，通过精确的指令协议驾驭 Agent
Cursor — Self-Driving	多 Agent 协同	背景 Agent 自动检测冲突并运行测试
Anthropic — Claude Code	长时运行稳定性	多层记忆系统 + CLAUDE.md 约束，让 Agent 在复杂任务中保持一致性

这些实践无疑令人兴奋。但在我们团队深度实践的过程中，我们逐渐意识到一个更本质的问题——

工作流只是管道，知识才是流过管道的活水。

正如 Harness 圆桌讨论中的一个核心论断所指出的：

"将来的技术护城河不在模型，而在垂直领域知识的沉淀。"

模型会迭代，工具链会更新，工作流会重构。但你的团队在一个特定业务领域积累的**领域模型、架构决策、最佳实践、已知陷阱、业务流程**——这些知识是永恒的，是不会因为模型换代而失效的。

这就是我们在 AI Team 项目中坚持的核心理念：

Skill、Agent、工具链会随模型迭代更新，但领域知识是永恒的。

二、Harness Engineering 本质：三支柱与知识的位置

在深入我们的实践之前，先简要回顾 Harness Engineering 的理论框架。Harness 的核心要素可以归结为三个支柱：

Harness Engineering 三支柱		
上下文工程	架构约束	持续治理
Context Eng.	Architecture	Governance
· 长/短期记忆	· Agent 编排模式	· 质量门禁
· 知识检索注入	· 状态机设计	· 知识生命周期
· 渐进式披露	· 降级策略	· 自动衰减
· 上下文防火墙	· 安全边界	· 持续进化

注意看"上下文工程"这个支柱——**知识检索注入**和**长/短期记忆**赫然在列。再看"持续治理"——**知识生命周期**和**自动衰减**也是核心组成部分。

换句话说，**知识管理本身就是 Harness Engineering 的核心能力**，而不是附属品。只是在当前的热潮中，大家更多关注了"工作流怎么编排""Agent 怎么协同"这些更显眼的工程话题，而忽略了底层的知识基础设施。

这就好比大家都在讨论高速公路该修几车道、立交桥该怎么设计，却忘了问：**路上跑的车（知识）从哪来？到哪去？怎么维护？**

三、核心论点：为什么知识沉淀比工作流更重要

我们在实践中总结出三个关键认知：

3.1 工作流是"可替换的"，知识是"可累积的"

今天用 16 阶段状态机编排 workflow，明天可能用图结构 DAG 编排。Agent 的调度模式从串行到并行到分层级联，变化很快。甚至于各大 SOTA 模型厂商也会逐渐内化和强化这种规划能力。但团队积累的知识——“广告预算扣减在高并发下会超扣，需用 Redis+Lua 保证原子性”——这条知识不管 workflow 怎么变，都是有价值的。

像 Anthropic 的 claude code 本身就是一个极其纯粹的 harness 实现，他们在 4 月份发的 **Emotion concepts and their function in a large language model** 论文就有类似的指向，可能未来的 Mythos 模型会通过探针系统 SAE 来实现模型的“情绪”稳定，进而从根本去实现 harness 希望解决的模型认知节省的问题。

3.2 没有知识沉淀的工作流是“一次性”的

我们观察到一个反模式：团队搭了很复杂的 Agent 工作流，每次需求都跑一遍全流程，但**每次都是从零开始**。上一次踩过的坑，下一次照踩不误。上一次做过的架构决策，下一次重新推导一遍。

这就是**没有知识闭环的工作流**——投入了工程成本搭建工具链，却没有让工具链变得越来越聪明。

3.3 知识是团队的“复利资产”

知识分为三类：**散点型知识**（孤立的事实）、**因果型知识**（A 导致 B 的推理链）、**时空型知识**（特定场景和时间窗口下才成立的经验）。越是高阶的知识，越难以从模型中获得，越依赖团队的实践积累。

当你的知识库有成百上千条 proven（经过多项目验证）的知识条目时，新来的成员、新启动的项目，都能“站在前人肩上”。**这就是知识的复利效应。**

四、知识分层架构：五层存储 × 五种类型 × 三级成熟度

在 AI Team 系统中，我们设计了一套三维正交的知识体系架构。

4.1 知识体系的三个维度

维度	回答的问题	定义
存储层（在哪）	知识存在哪里？	Layer 0-P 0-T 1 2 3 — 从个人到团队到项目
知识类型（是什么）	知识描述的是什么？	model decision guideline pitfall process
成熟度（多可信）	知识经过多少验证？	draft → verified → proven

4.2 五层存储架构

五层知识存储			
Layer 0-P	个人偏好 (~/.ai-team/)	纯本地，不共享	
Layer 0-T	团队约定 (team-conventions/)	团队级，Git 共享	
Layer 1	技术知识 (tech-wiki/)	团队级，跨项目	
Layer 2	业务知识 (biz-wiki/{domain}/)	团队级，按领域	
Layer 3	项目知识 (docs/knowledge/)	项目级，随项目走	

为什么要分五层？ 因为不同范围的知识有不同的共享边界和生命周期。

- **Layer 0-P**（个人偏好）：你喜欢 4 空格缩进还是 2 空格？偏好函数式还是面向对象？这是纯个人的，不应该强制给团队。
- **Layer 0-T**（团队约定）：代码规范、Commit 规范、Review 标准。这是团队层面的"宪法"，相对稳定。
- **Layer 1**（技术知识）：跨项目通用的技术经验。比如"Spring Boot 多租户拦截器设计模式"、"Optional 依赖传递陷阱"。
- **Layer 2**（业务知识）：特定业务领域的领域模型、业务规则、业务流程。比如"广告审核流程：提交→机审→人审→上线"。
- **Layer 3**（项目知识）：仅在当前项目有意义的上下文。比如"本项目数据库用的是 TencentDB for MySQL 8.0"。

关键设计：知识可以"向上提升"。 Layer 3 的项目知识，如果被判定为跨项目通用，会自动提升到 Layer 1 或 Layer 2。

Layer 3（项目内）	
	所有类型，maturity 为 draft
→	Q1: 是否项目特有？ → 是：留在 Layer 3
→	Q2: 是否通用技术？ → 是：提升到 Layer 1 (tech-wiki)
→	Q3: 是否通用业务？ → 是：提升到 Layer 2 (biz-wiki)

4.3 五种知识类型

知识按"描述的是什么"分类，遵循 MECE（互斥且完全穷尽）原则：

类型	定义	示例
model	实体定义、数据结构、关系图	"广告计划包含预算/出价/投放时段三个核心字段"
decision	技术选型、架构决策及理由	"选择事件驱动而非 RPC 同步，因为广告状态变更需要解耦"
guideline	推荐做法 (recommend) 或禁止做法 (avoid)	recommend: "公共模块变更后的兼容性检查清单"
pitfall	已知风险、故障模式、排查步骤	"广告预算扣减在高并发下会超扣"
process	业务流程、状态机、操作步骤	"广告审核：提交→机审→人审→上线"

这五种类型覆盖了我们在实践中遇到的所有知识形态。每一条知识只属于一个类型，来源信息记录在元数据中用于溯源分析。

4.4 三级成熟度 + 自动衰减

知识不是"写完就完了"。它有生命周期。

draft（新提取，单一来源）

↓ 在 1 个工作流中被成功引用

verified（单项目验证）

↓ 在 ≥2 个不同项目中被验证

proven（成熟/可信赖）

更关键的是**自动衰减机制**——知识如果长期不被引用，会自动降级：

触发条件	衰减动作
proven 条目 12 个月未被引用	降级为 verified
verified 条目 6 个月未被引用	降级为 draft
draft 条目持续未引用 + Lint 标记	归档，移出活跃索引

为什么需要衰减？ 因为知识也会过时。一条三年前的"最佳实践"，可能因为框架版本升级已经不再适用。与其让过时知识误导 Agent，不如让它自然衰减退出活跃库。

这个设计借鉴了 Karpathy 在 LLM Wiki 概念中提出的 **Lint 操作**——定期识别矛盾、孤儿页、缺失交叉引用和数据缺口。

五、团队知识库：如何共享和更新

5.1 独立 Git 仓库 —— 知识的"单一事实来源"

我们做了一个关键的架构决策：**团队知识库是一个独立的 Git 仓库**，不寄生于任何业务项目。

```
team-knowledge.git          ← 独立 Git 仓库
├─ knowledge-catalog.md    ← 全景目录（Agent 查询入口）
├─ .knowledge-config.yaml  ← 团队配置（成员、冲突策略）
├─ team-conventions/       ← Layer 0-T：团队约定
│   └─ coding-standards.md
│   └─ commit-conventions.md
├─ tech-wiki/              ← Layer 1：技术知识
│   └─ catalog.md          ← 分类清单
│   └─ patterns/TK-PAT-001.md
│   └─ anti-patterns/TK-AP-001.md
├─ biz-wiki/               ← Layer 2：业务知识
│   └─ {domain}/
│       └─ catalog.md
│       └─ entities/BK-AD-E001.md
│       └─ pitfalls/BK-AD-P001.md
├─ project-profiles/       ← 项目画像
└─ contributions/         ← 贡献暂存区
    └─ pending/
    └─ conflicts/
```

为什么要独立仓库？

- 跨项目共享**：同一个团队的多个项目连接同一个知识仓库，项目 A 沉淀的知识，项目 B 自动受益。
- 生命周期独立**：业务项目可能归档或重构，但知识不应该跟着项目消失。
- 权限独立**：知识库的贡献和消费权限可以独立于代码仓库管理。

5.2 三种团队角色

角色	权限	适用人群
maintainer	裁决内容冲突、审批 proven 提升、管理成员	团队负责人、资深工程师
contributor	通过工作流自动贡献（创建/验证/标记矛盾）	正式团队成员
reader	只消费知识（查询/注入），不贡献	新成员试用期

5.3 贡献模式 —— "贡献暂存 + 异步合并"

我们借鉴了区块链的三个核心思想，但用 Git 作为实现载体：

区块链思想	AI Team 实现	机制
不可篡改的追加日志	log.md 只追加不修改	每条变更记录贡献者、时间、会话哈希
贡献可溯源	evidence.contributors []	类似 Git blame，粒度为知识条目级
共识机制	maturity 多人验证提升	draft→verified: 1 人验证; verified→proven: ≥2 人 + ≥2 项目

log.md 示例：

```
## [2026-04-09] ingest | [Steven] | 门店履约视图归档 | +1 decision, +2 guideline | #a3f8c2
- 新增 DEC-005: 地图组件选型（腾讯地图 GL JS SDK）
- 新增 GL-012: fitBounds 在 flexbox 布局中的替代方案 (polarity=recommend)

## [2026-04-12] verify | [Alice] | 跨项目验证 | maturity↑ 2 | #c5f0e2
- TK-SB-003 "分页查询延迟关联优化" (verified→proven, 2 projects)
```

5.4 冲突解决策略

当多名成员同时向知识库贡献时，按以下策略自动处理：

冲突类型	处理方式
纯新增 (不同条目)	自动合并，两条都保留
证据追加 (同条目验证)	自动合并，evidence 数组合并去重
成熟度提升	自动合并
内容矛盾	写入 contributions/conflicts/，通知 maintainer 裁决
成熟度冲突 (一升一降)	保留较低成熟度 + 标记 contradiction


设计理念：大多数情况（纯新增、证据追加、成熟度提升）可以自动处理，只有真正的内容矛盾才需要人工介入。这让知识的共建过程尽可能低摩擦。

六、工作流如何服务于知识沉淀

现在回到工作流。在 AI Team 系统中，我们的 16 阶段状态机不是为了"好看"或"复杂"——它的每一个阶段都与知识的流动紧密关联。

6.1 知识的完整生命周期：三通道沉淀





三个关键时刻：

- 1. **INIT 阶段（知识注入）**：工作流启动时，自动 `git pull` 团队知识仓库，将知识全景目录注入 Agent 的查询入口。新启动的工作流自动站在前人肩上。
- 2. **各阶段执行中（知识消费）**：Agent 在决策点按需查询知识库。比如 `@tech-explore` 在技术分析阶段查询"有没有类似的架构决策"，`@backend-architect` 在架构设计阶段查询"有没有已知的反模式"。
- 3. **ARCHIVE 阶段（知识提取）**：工作流完成后，`@archiver` 自动从全流程产物中提取知识条目——架构决策变成 `decision`，踩过的坑变成 `pitfall`，总结的经验变成 `guideline`。提取后执行提升判定，符合条件的自动提升到 Layer 1 或 Layer 2。

6.2 各阶段查询什么知识

每个阶段的 Agent 有独立的查询预算，聚焦不同类型的知识：

阶段	查询焦点	重点知识类型
ANALYSE_PRODUCT	业务知识 (Layer 2) + 历史需求	model, process, pitfall
ANALYSE_TECH	技术知识 (Layer 1) + 归档索引	decision, guideline(avoid), pitfall
ARCHITECT	架构模式 + 实体关系	decision, model
IMPLEMENT	编码实践 + 团队约定	guideline, pitfall
BUILD_VERIFY	反模式库	pitfall, guideline(avoid)

为什么要限制查询预算？ 因为 Agent 如果无限制地读取知识库，会导致上下文膨胀——这恰恰是 Harness Engineering 要解决的核心问题之一。我们通过预算控制，让知识消费"精准"而非"贪婪"。

6.3 冷启动导入 —— /flow-import

对于历史项目（已有大量代码但没有知识库），我们提供了 `/flow-import` 命令，通过 3 个 Agent 的管道实现冷启动：



所有产出条目初始 maturity 为 **draft**，后续工作流的执行会逐步验证和提升它们。

七、知识的按需消费：三级索引 + 查询预算

7.1 从"推送"到"主动查询"的范式转变

传统做法是在 Agent 启动时，把一堆知识"推送"给它。这有两个问题：

- **信息过载**：推送太多知识，Agent 反而被淹没，找不到关键信息。
- **不精准**：预先推送的知识不一定是 Agent 当前决策点需要的。

我们的设计理念是：**Agent 不被动接收固定数量的知识推荐，而是通过三级渐进式索引主动按需查阅。**

7.2 三级渐进式索引

借鉴 Karpathy 的 LLM Wiki Pattern，我们设计了三层索引结构：

层级	文件	大小	作用
Layer A: 全景目录	knowledge-catalog.md	~50 行	"知识库有什么？"——分类统计 + 按阶段推荐查阅路径
Layer B: 分类清单	各目录下的 catalog.md	~100-300 行	"这个分类有哪些条目？"——每条一行摘要 (ID + 标题 + 成熟度 + 标签)
Layer C: 完整条目	TK-*.md / BK-*.md	~50-200 行	"这条知识说了什么？"——完整内容 + 背景 + 适用场景

渐进查询流程：

- Step 1: 读全景目录 (~50 行, 零成本)
- 了解知识库有什么分类、每类多少条
 - 定位当前阶段推荐查阅的 catalog.md 路径
- Step 2: 读分类清单 (~100-300 行, 低成本)
- 每条知识一行摘要
 - 按 tags / applicable_phases 过滤相关条目
- Step 3: 读完整条目 (按需, 每条 50-200 行)

→ 获取完整知识内容

Step 4: 读原始产物（深入，可选）

→ 沿 `source_references` 追溯原始推导过程

这意味着 Agent 可以用 **~50 行的成本** 了解知识库全貌，用 **~300 行的成本** 定位到相关条目，只在真正需要时才读取完整内容。对比“一次性推送 50 条完整知识”（可能 5000-10000 行），上下文效率提升了一个数量级。

7.3 知识引用追踪闭环

Agent 查询知识后，在输出产物中记录引用：

```
{
  "knowledgeReferences": [
    { "id": "TK-SB-003", "title": "分页查询延迟关联优化", "usedIn": "复用评级 Step 2" },
    { "id": "BK-AD-G004", "title": "广告预算扣减并发控制规则", "usedIn": "业务规则参考" }
  ]
}
```

ARCHIVE 阶段会读取所有阶段产物中的 `knowledgeReferences`，批量更新 `evidence.last_referenced` 字段。这形成了**自动化的引用追踪闭环**——被引用的知识 maturity 会自动提升，长期未引用的会自动衰减。

八、突破人机交互瓶颈：随时随地保障工作流流转

前面七个章节聚焦于“知识如何沉淀”和“工作流如何服务于知识”。但在实际落地中，我们遇到了一个被普遍忽视的工程现实——

工作流的流转依赖于人的在场。

16 阶段状态机设计得再精密，如果 Agent 在执行过程中需要人工确认（比如架构评审节点、产物验收节点），而你恰好在开会、通勤、或者吃饭——工作流就卡住了。这不是知识架构的问题，而是**人机交互模式**的瓶颈。

8.1 问题：Harness 工作流的"在场依赖"

传统的 Agent 工作流有一个隐含假设：**操作者坐在电脑前，IDE 打开着，随时可以响应 Agent 的请求。**

但现实是：

一个典型的工作日		
09:00	站会	✗ 无法响应 Agent
10:00	坐在工位	✓ 可以操作
11:30	技术评审会	✗ 无法响应 Agent
12:00	午饭+午休	✗ 无法响应 Agent
14:00	坐在工位	✓ 可以操作
15:30	跨团队沟通	✗ 无法响应 Agent
17:00	通勤回家	✗ 无法响应 Agent
20:00	在家想处理	✗ 内网环境不可达

一天 8 小时工作，真正能"坐在工位操控 Agent"的时间可能不到 4 小时。更关键的是，那些"碎片时间"——会议间隙的 5 分钟、通勤路上的 30 分钟、晚饭后想 review 一下——恰恰是 Agent 需要你确认的黄金窗口。

如果工作流在你离开时就暂停，在你回来时才继续，那工作流的效率至少折半。

8.2 解法：远程操控 + 跨设备接管

在实际工程实践中，我们引入了 Hapi 内网版来解决这个问题。它的核心能力是：

在办公网下（不需要开启IOA远程工作，微信或企微均可直接打开），用手机远程接管运行在开发机上的 AI 编程会话。

这意味着：

改进后的工作模式		
09:00	站会	📱 手机扫一眼 Agent 进展
10:00	坐在工位	💻 IDE 深度操作

11:30	评审会间隙	手机确认 Agent 架构方案
12:30	午饭后	手机 review Agent 产物
14:00	坐在工位	IDE 深度操作
15:30	跨团队沟通后	手机批准 Agent 下一阶段
17:30	通勤路上	手机启动新工作流
20:00	在家	浏览器远程操控开发机

核心能力矩阵：

能力	说明	对 Harness 工作流的意义
跨设备会话接管	手机/平板/电脑均可接管同一 Agent 会话	工作流不因设备切换而中断
24 小时待机	开发机上的 Agent 持续运行	工作流可以 7×24 小时流转
PWA 原生体验	安装到桌面后像原生 App	降低远程操控的使用门槛
多助手切换	支持 Codebuddy/Codex/Gemini 等	适配不同 Agent 引擎的工作流
自主模式	YOLO 模式让 Agent 自主执行	减少人工确认频率

8.3 与知识沉淀闭环的结合

远程操控能力不仅解决了"人机交互"的效率问题，更重要的是**保障了知识沉淀闭环的完整性**。

回顾第六章的知识流动路径：

INIT（知识注入）→ 各阶段执行（知识消费）→ ARCHIVE（知识提取）

需要说明的是，由于我们的 Harness 工作流采用"文件系统即状态机"的设计，**暂停本身不会丢失任何进度**——所有阶段产物和状态都持久化在文件中，随时可以从断点恢复。但暂停过久带来的真正问题是**效率和时效性**：

- 交付周期拉长**：一个原本 Agent 可以连续推进的需求，因为卡在人工确认节点（如架构评审、产物验收），从 1 天交付变成 3 天交付。工作流没出错，只是在"等人"。
- 知识沉淀的时效性下降**：ARCHIVE 阶段的知识提取依赖工作流完整走完。流程卡得越久，新产生的知识沉淀到团队知识库的速度就越慢，后续需求无法及时消费到最新的经验。
- 碎片时间浪费**：你在会议间隙有 5 分钟、通勤路上有 30 分钟，这些碎片时间本可以推进工作流，但因为不在工位、没有 IDE 环境而白白流失。

有了远程操控能力后，这些碎片时间都能被利用——工作流可以**更紧凑地走完全流程**，从 INIT 的知识注入，到各阶段的知识消费和决策确认，到 ARCHIVE 的知识提取和自动提升，大幅缩短交付周期，加速知识沉淀闭环的流转。

8.4 工程架构设计启示

这个经验给我们的 Harness 工程架构设计带来一个重要启示：

好的 Harness 工程不仅要设计"Agent 怎么跑"，还要设计"人怎么随时参与"。

具体到架构层面，这意味着：

- **状态持久化**：工作流的状态必须是持久化的（文件系统即状态机），而不是存在内存中。这样无论从哪个设备接入，都能看到一致的状态。
- **断点恢复**：每个阶段的入口和出口都有明确的持久化产物，支持从任意断点恢复。
- **异步审批**：人工确认节点应设计为异步模式——Agent 提交产物、暂停等待，人类可以在任意时间、任意设备上审批后，Agent 继续执行。
- **通知触达**：关键节点（如架构评审、产物验收）应通过企业微信等渠道主动推送，而非被动等待人来检查。

这些设计与 AI Team 的"文件系统即状态机"哲学天然契合——所有状态都在文件中，不依赖内存或特定进程，远程设备通过 Web 界面看到的就是真实的工作流状态。

九、落地经验与思考

9.1 历史项目引入：从 0 到 1 的冷启动挑战

最大的挑战不是设计架构，而是**让已有项目的隐性知识显性化**。很多团队的知识散落在 Wiki、TAPD 评论、企业微信聊天记录、甚至团队成员的脑子里。

我们的做法是：

1. **多源收集**：`/flow-import` 支持 Git 仓库扫描、TAPD 需求拉取、iWiki 文档导入、本地文档解析、口述录入等多种输入方式。
2. **渐进导入**：不追求一次性导入完美，所有导入知识初始 maturity 为 `draft`（置信度 0.5-0.6），通过后续工作流的实际使用逐步验证提升。
3. **断点恢复**：导入过程通过 `import-state.json` 持久化进度，支持中断后继续。

9.2 知识膨胀治理：Lint 机制

知识库不能只进不出。我们设计了定期的 Lint 机制（借鉴 Karpathy 的 LLM Wiki）：

检查项	处理方式
索引不一致	自动修复
孤儿条目（无引用、无验证）	降级为 draft
矛盾检测（同主题相反结论）	标记冲突，等待 maintainer 裁决
过时检测（6 月未引用的 draft）	自动归档
重复/相似条目	标记合并候选
成熟度衰减	按规则自动降级

Lint 触发方式包括：每完成 10 个工作流自动触发、[/knowledge lint](#) 手动触发、连续 30 天未执行时在下次 [/flow-run](#) 启动时提醒。

9.3 Big Model vs Big Harness —— 我们的务实立场

业界存在一场争论：该投入更多在"更大更强的模型"上，还是"更复杂的 Harness"上？

我们的立场是：**这不是非此即彼的选择，而是要找到适合你团队的平衡点。**

- 模型能力提升是大势所趋，投在知识工程上的架构应该**对模型能力的提升保持开放**——当模型更强时，同样的知识可以被更好地利用。
- 但模型能力提升**不能替代**领域知识。再强的模型也不知道你的业务系统里有哪些隐藏的坑。
- **知识工程的投入是确定性回报**：每沉淀一条 proven 知识，所有后续工作流都受益。而模型能力提升的回报是概率性的，你不知道下一代模型在你的特定场景上是否真的更好。

9.4 从"文件即状态"到"知识即资产"

AI Team 的设计哲学中，有一条看似朴素但非常重要的原则：**文件系统即状态机**。所有的状态、产物、知识都以文件形式存在，没有数据库、没有独立平台。

这不是技术妥协，而是刻意选择：

- **可见性**：所有知识都是 Markdown 文件，人可以直接阅读、编辑、审查。
- **可版本化**：Git 管理的文件天然有版本历史。
- **可迁移性**：不依赖任何特定平台或服务，换工具链时知识不会丢失。
- **IDE 原生**：[.codebuddy/](#) 目录驱动，被 IDE 原生识别，零配置成本。

十、总结与展望

回到文章开头的核心论点：**Harness 不是目的，知识才是护城河。**

我们在 AI Team 项目中的实践表明：

1. **知识分层管理**（五层存储 × 五种类型 × 三级成熟度）让知识有了清晰的组织结构，Agent 可以精准按需消费。
2. **团队知识库共建共享**（独立 Git 仓库 + 三种角色 + 自动冲突解决）让知识从"个人经验"变成"团队资产"。
3. **工作流服务于知识沉淀**（INIT 注入 → 各阶段按需查询 → ARCHIVE 自动提取）让每次需求交付都是一次知识积累。
4. **知识的按需消费**（三级渐进式索引 + 查询预算）解决了上下文膨胀与知识利用的平衡。
5. **知识的生命周期管理**（自动衰减 + Lint 机制 + 引用追踪闭环）让知识库保持健康和活力。
6. **突破人机交互瓶颈**（远程操控 + 跨设备接管 + 异步审批）让工作流 7×24 小时顺畅流转，保障知识沉淀闭环的完整性。

展望未来，我们认为有几个方向值得探索：

- **知识的语义检索增强**：当前的三级索引是基于结构化标签的过滤，未来可以引入向量检索实现语义级的知识发现。
- **跨团队知识联邦**：不同团队的知识仓库之间如何安全地共享通用技术知识（Layer 1），同时保护业务知识（Layer 2）的边界。
- **知识质量的自动评估**：除了基于引用频率的成熟度提升，能否用模型来评估知识条目的质量和时效性。
- **全异步工作流**：结合远程操控能力，探索完全异步的人机协作模式——Agent 自主执行非关键路径，仅在关键决策点异步通知人类审批，进一步释放工作流的 7×24 小时潜力。

最后，引用我们在项目 README 中写的那句话作为结尾：

Skill、Agent、工具链会随模型迭代更新，但领域知识是永恒的。AI Team 的每次交付都自动沉淀知识到团队共享仓库，所有成员共建共享，新工作流启动时自动站在前人肩上。

这就是我们对 Harness Engineering 的理解——**工作流是手段，知识是目的。**

参考文献：

Karpathy LLM Wiki — 知识复合增长：Ingest + Query + Lint



腾讯技术工程

腾讯技术官方号。腾讯技术创新、前沿领域发布解读平台。

634篇原创内容

公众号

